

Roteiro de Práticas Extensionistas IV - Entregáveis

1. Pré-projeto

A ser entregue em documento Word / PDF:

- Definição de assunto, tema, título
 - Assunto: A área geral (exemplo: 'Informática na Educação', 'Agricultura de Precisão').
 - Tema: O recorte específico dentro da área (exemplo: 'Uso de dados para prever evasão escolar em escolas públicas', 'Monitoramento de umidade do solo para pequenos agricultores').
 - Título: O nome do projeto, que deve ser claro e atrativo (exemplo: 'Sistema de Alerta Precoce de Evasão Escolar para a Rede Municipal de X').
- Delimitação / escopo
- Problema
- Questão de pesquisa
- Hipóteses
- Justificativa
- Análise de relevância regional e sustentabilidade
 - Como este projeto contribui para os setores produtivos do Oeste Catarinense?
 - Quais os ganhos ambientais ou de eficiência de recursos a solução promove?
 - Qual o impacto social direto na comunidade parceira?
 - Potencial de inovação e empreendedorismo: Verificar se a solução pode evoluir para um plano de negócios ou uma startup, gerando valor contínuo para a região
- Objetivo geral
- Objetivos específicos
- Cronograma
- Estudo (estimativa de viabilidade)
 - Viabilidade técnica: A equipe possui as habilidades (Python, SQL, *dashboards*) e os dados necessários estão acessíveis?
 - Viabilidade operacional: A comunidade (escola, associação, ONG) tem infraestrutura (internet, computadores) para usar a solução? Eles estão dispostos a colaborar?
 - Viabilidade de tempo: É possível coletar, limpar os dados e gerar o modelo em apenas um semestre? (em Ciência de Dados, a limpeza de dados costuma consumir 60-70% do tempo).
 - Viabilidade de manutenção: Avaliar se a comunidade parceira tem condições de manter e atualizar a solução após a entrega
- Implantação / *deployment*: Mostra onde e como o *software* irá rodar (exemplo: *notebook do cientista, servidor na nuvem, navegador do usuário*). Importante para discutir infraestrutura e custos.
- Plano de validação e critérios de aceite: A ser feito após a definição dos requisitos
 - Métricas de sucesso do modelo: Liste as métricas (Acurácia, F_1 -Score, RMSE) e os valores mínimos aceitáveis para cada uma. Justifique por que esses valores são suficientes para o problema real.
 - Protocolo de teste de aceite (UAT - *User Acceptance Testing*): Descreva como a comunidade vai testar.
 - Exemplo: 'Serão realizados 3 cenários de teste com 5 usuários reais da associação, onde eles deverão tentar gerar um relatório sem ajuda da equipe técnica.'
 - Condições de "pronto" (*definition of done*): O que falta para considerar a tarefa finalizada?
 - Código revisado + Modelo treinado com métrica X atingida + Dashboard validado pelo gestor + Manual entregue.
 - Gestão de expectativas (limites do modelo): Deixe claro o que o sistema NÃO fará.
 - Exemplo: 'O sistema auxilia na decisão, mas não a automatiza totalmente. A decisão final de plantio permanece com o agricultor.' (isso evita rejeição por expectativas irreais de 'IA mágica').

2. Modelagem

Unir o texto e os diagramas em um documento e enviar nos formatos Word / PDF:

- **Diagrama de blocos** (arquitetural): Foco na visão geral da arquitetura. Não é um diagrama UML padrão, mas é crucial em Data Science.
 - O que modelar: Os grandes blocos do *pipeline*: Coleta de Dados → Armazenamento (Data Lake/Warehouse) → Processamento/ETL → Modelagem (ML) → Visualização.
- **Casos de uso** (foco no usuário e no analista): Em Ciência de Dados, os 'atores' geralmente são o **Gestor / Cliente** (que consome o *insight*) e o **Cientista de Dados / Admin** (que alimenta ou monitora o modelo)
 - Quantidade: No mínimo 3 casos de uso.
 - Exemplos típicos:
 - 'Visualizar Previsão de Demanda' (gestor).
 - 'Gerar Relatório de Segmentação de Clientes' (gestor).
 - 'Atualizar Base de Dados de Treinamento' (administrador).
 - 'Monitorar Acurácia do Modelo' (cientista de dados).
- **Requisitos funcionais** (foco no *pipeline* de dados): Devem descrever as capacidades do sistema de transformar dados em informação.
 - Quantidade: No mínimo 5 requisitos
 - O que incluir:
 - **Entrada de Dados:** 'O sistema deve permitir a importação de dados em formato CSV/Excel de fontes externas.'
 - **Pré-processamento:** 'O sistema deve tratar automaticamente valores nulos ou inconsistentes na base de entrada.'
 - **Modelagem:** 'O sistema deve executar o algoritmo de regressão para prever vendas com base no histórico de 12 meses.'
 - **Saída/Visualização:** 'O sistema deve apresentar os resultados em dashboards interativos com filtros por região e período.'
- **Requisitos não funcionais** (críticos em Data Science)
 - Aqui reside a maior complexidade em projetos de dados. Devem ser **rigorosamente mensuráveis**.
 - Quantidade: No mínimo 4 (focados em qualidade).
 - Principais categorias:
 - **Desempenho (tempo de processamento):** 'O modelo preditivo deve gerar as previsões para 10.000 registros em menos de 2 minutos.' (diferente de sistemas web que focam em tempo de resposta de clique).
 - **Acurácia/precisão:** 'O modelo de classificação deve atingir uma acurácia mínima de 85% na base de teste.' (requisito exclusivo de projetos de IA/Dados).
 - **Escalabilidade de dados:** 'O sistema deve suportar bases de dados de até 5 GB sem degradação significativa de performance.'
 - **Privacidade e ética:** 'Os dados sensíveis dos clientes devem ser anonimizados antes do processamento pelo modelo, em conformidade com a LGPD.'
- Diagrama E/R (versão inicial)

Caso necessário, outros diagramas podem ser confeccionados, como:

- BPMN / diagrama de atividades (UML)
- Diagrama de sequência
- Diagrama de (máquina de) estados

3. Desenvolvimento

Entregáveis:

- Código
 - URL do repositório no GitHub
 - URL do *notebook* do Google Colab / arquivos *.ipynb* (também devem estar no GitHub) contendo a **Análise Exploratória de Dados (EDA)**, o tratamento (limpeza) e o treinamento dos modelos – eles devem servir como "caderno de laboratório", mostrando o raciocínio passo a passo
 - Arquivo de dependências: Um *requirements.txt* ou *environment.yml* listando todas as bibliotecas e versões exatas para garantir que outro desenvolvedor consiga rodar o projeto sem erros de compatibilidade
 - *README.md*: Documentação inicial no repositório explicando como instalar, configurar e executar o projeto
 - Documentação técnica
- Artefatos de modelo e dados
 - Modelos serializados: Os arquivos dos modelos treinados e prontos para uso (exemplos: *.pkl*, *.h5*, *.joblib*, *.onnx*) – isso evita que o usuário final precise retreinar o modelo do zero
 - *Pipeline* de dados (ETL): O código ou fluxo que realiza a extração, limpeza e transformação dos dados brutos para o formato utilizável pelo modelo
 - Base de dados tratada (anonimizada): Se permitido eticamente e pela LGPD, entregar o *dataset* já limpo e estruturado que foi usado para treinar o modelo, facilitando estudos futuros ou auditorias – atenção: dados sensíveis devem ser sempre anonimizados ou excluídos
 - Demais artefatos caso não estejam no repositório do GitHub
- *Interface* e aplicação: Para a comunidade extensionista, o código 'bruto' tem pouco valor; eles precisam de uma *interface* para interagir com o sistema.
 - *Dashboard* interativo: Entregável comum em projetos semestrais, feito em ferramentas como Streamlit, Power BI, Tableau ou Plotly Dash. Permite que o usuário filtre dados e veja as previsões sem tocar em código.
 - API funcional (opcional/avançado): Se o sistema for integrar com outras ferramentas da organização, entrega-se uma API (exemplos: feita em FastAPI ou Flask) que recebe dados e retorna previsões em formato JSON.
 - Protótipo executável: Um *script* ou aplicação que o usuário final possa rodar para obter o resultado esperado (exemplo: 'Gerar Relatório de Safra').

4. Cronograma

O cronograma é dividido em três fases principais:

- **Planejamento e modelagem**
- **Desenvolvimento e iteração**
- **Validação e entrega**

Fases e entregas:

- **Fase 1: Planejamento, modelagem e pipeline mínimo (14/08 – 27/09)**
Objetivo: Entregar o projeto especificado e um *pipeline* de dados funcional (ETL básico) que prove a viabilidade técnica.
- **Sprint 1 (14/08 – 28/08): Definição e acesso a dados**
 - Definição de assunto, tema, título e problema.
 - **Ação crítica:** Solicitação e obtenção imediata da amostra de dados brutos.
 - Contato inicial com a comunidade para validar o problema.
 - Elaboração do estudo de viabilidade e pré-projeto.
 - **Entregáveis:** Pré-Projeto (objetivos, justificativa, metodologia, viabilidade (técnica, operacional e de dados).
- **Sprint 2 (31/08 – 11/09): Requisitos e Modelagem**
 - **Diagrama de blocos** (arquitetura do *pipeline*).
 - Levantamento de requisitos (RF, RNF) e casos de uso.
 - Criação de outros diagramas caso necessário: **BPMN** (Processo de Negócio), sequência, etc.
 - Diagrama E/R inicial.
 - Definição dos critérios de aceite (métricas de modelo e negócio).
 - **Entregáveis:** Documento de especificação (requisitos + diagramas).
- **Sprint 3 (14/09 – 27/09): Coleta, Preparação e Implementação do *pipeline* de Dados (ETL)**
 - Desenvolvimento do *script* de **Extração e Limpeza** (tratamento de nulos, padronização).
 - Criação do primeiro *notebook* de Análise Exploratória (EDA) básico.
 - Consolidação da documentação para entrega.
 - **Entregáveis:** *Notebook* desenvolvido.

ENTREGA PARCIAL (27/09) Obrigatoriedade: Deve conter o *pipeline* de Dados em execução (código que lê o dado bruto e entrega um *dataset* tratado).

Pacote de entrega:

1. **Pré-projeto completo:** Com viabilidade confirmada e cronograma.
2. **Estudo de viabilidade:** Confirmação de acesso aos dados e infraestrutura.
3. **Especificação:** Requisitos, casos de uso priorizados e diagramas (BPMN validado pelo cliente + blocos + E/R).
4. **Pipeline inicial:** *Script/Notebook* de ETL funcional + *Dataset* tratado (amostra).
5. **EDA Inicial:** Primeiros gráficos descritivos dos dados limpos.
6. **Protótipo de baixa fidelidade:** Esboço das telas ou fluxos do *dashboard* (opcional, mas recomendado).

- **Fase 2: Modelagem Preditiva e Desenvolvimento do Sistema (27/09 – 21/11)**

Objetivo: Transformar os dados tratados em inteligência (modelo) e disponibilizar via *interface*.

- **Sprint 4 (28/09 – 18/10): Análise Exploratória Avançada, ETL e *feature engineering***

- Aprofundamento na EDA para seleção de variáveis.
- Extração dos dados brutos da fonte real.
- Criação de novas *features* (engenharia de atributos) para melhorar o modelo.
- Limpeza, tratamento de valores nulos e engenharia de *features*.
- **Entregável:** *Dataset* final tratado para treino e documentado e relatório de *insights*.

- **Sprint 5 (19/10 – 08/11): Treinamento e Validação de Modelos**

- Seleção de algoritmos
- Treinamento e validação cruzada de algoritmos de *Machine Learning*.
- Ajuste fino (*hyperparameter tuning*) para atingir as métricas de aceite.
- Avaliação contra os **critérios de aceite** definidos na Fase 1.
- **Entregável:** Modelo treinado (.pkl/.h5) e relatório de métricas (acurácia, *recall*, etc.) – se possível já com as métricas validadas.

- **Sprint 6 (09/11 – 21/11): Desenvolvimento da *Interface* (*dashboard* / API)**

- Codificação do *dashboard* (ex: Streamlit / PowerBI) ou API.
- Integração do modelo treinado ao *pipeline* de inferência e *interface*.
- **Entregável:** Sistema Beta funcional (*end-to-end*).

- **Fase 3: Validação, Refinamento e Encerramento (22/11 – 06/12)**

Objetivo: Validar a solução com o usuário real e documentar o projeto final.

- **Sprint 7 (22/11 – 29/11): Testes e validação com Usuário (UAT)**

- Apresentação da solução para a comunidade parceira.
- Testes com a comunidade parceira.
- Coleta de *feedback* e ajustes finos (*bugs*, usabilidade, clareza dos *insights*).
- Validação formal dos **critérios de aceite**.
- Ajustes de usabilidade e correção de *bugs* críticos reportados.

- **Sprint 8 (30/11 – 06/12): Documentação Final e Entrega (Empacotamento)**

- Redação do relatório técnico, manual do usuário e artigo (opcional).
- Organização e limpeza final do repositório Git (README, requirements.txt, código limpo).
- Preparação da apresentação final.

ENTREGA FINAL (06/12)

Pacote completo:

1. **Sistema completo e funcional:** *Dashboard*/API/aplicação rodando em produção.
2. **Código Fonte:** Repositório Git completo com *notebooks*, *pipeline*, *scripts* de treino e aplicação.
3. **Artefatos de modelo:** Arquivo do modelo serializado e *dataset* tratado (anonimizado).
4. **Documentação técnica:** Relatório final com metodologia, métricas alcançadas e lições aprendidas.
5. **Documentação de usuário:** Manual simples de como usar a ferramenta
6. **Apresentação:** *Slides* ou vídeo demonstrando o impacto na comunidade.

Resumo visual das datas chave:

Data	Marco	Entregável Crítico
28/08	Fim <i>Sprint</i> 1	Dados Brutos em mãos.
11/09	Fim <i>Sprint</i> 2	Requisitos e Diagramas fechados.
26/09	ENTREGA PARCIAL	<i>Pipeline</i> ETL funcional + Pré-Projeto.
11/10	Fim <i>Sprint</i> 4	<i>Dataset</i> final para treino pronto.
25/10	Fim <i>Sprint</i> 5	Modelo de ML validado.
08/11	Fim <i>Sprint</i> 6	Sistema integrado (<i>beta</i>).
22/11	Fim <i>Sprint</i> 7	Sistema validado pelo usuário.
06/12	ENTREGA FINAL	Projeto completo e documentado.